

Regresión Robusta

Roberto C. Duarte

Universidad de Buenos Aires

Noviembre 2022

Ejemplo (**Ejemplo 1**)

*En un experimento sobre la velocidad de aprendizaje de las ratas, se registraron los tiempos que tardan en pasar por una **shuttlebox** en varios intentos. Si el tiempo superaba los 5 segundos la rata recibía una descarga eléctrica durante el siguiente intento. Los datos son el número de descargas recibidas y el tiempo medio de todos los intentos entre descargas.*


Valores atípicos e influyentes



M Estimadores de regresión



Regresión Logística




Valores atípicos e influyentes




M Estimadores de regresión



Regresión Logística







Outlier y punto influyente

- **Valor atípico:** Es una observación que es numéricamente distante del resto de los datos.
- **Punto influyente:** Punto que tiene impacto en las estimaciones del modelo.


Valores atípicos e influyentes



M Estimadores de regresión



Regresión Logística




Valores atípicos e influyentes



M Estimadores de regresión



Regresión Logística




Valores atípicos e influyentes




M Estimadores de regresión



Regresión Logística





Definición (**Leverage**)

Sea $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ la matriz de proyección, llamamos "leverage" (apalancamiento) de la observación \mathbf{x}_i al elemento $h_{ii} = \mathbf{x}_i'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_i$ de la matriz de proyección.

$$0 \leq h_{ii} \leq 1$$

$$\sum_{i=1}^n h_{ii} = \text{Rango}(\mathbf{X})$$



$$h_{ii} = \frac{1}{n} + (\mathbf{x}_i - \bar{\mathbf{x}})'(\mathbf{X}^*'\mathbf{X}^*)^{-1}(\mathbf{x}_i - \bar{\mathbf{x}})$$

$\bar{\mathbf{x}}$ es el vector de promedios de los \mathbf{x}_i y \mathbf{X}^* es la matriz de dimensión $n \times (p-1)$ cuya i -ésima fila es el vector $(\mathbf{x}_i - \bar{\mathbf{x}})'$.


$$h_{ii} = \frac{1}{n} + (\mathbf{x}_i - \bar{\mathbf{x}})'(\mathbf{X}^*'\mathbf{X}^*)^{-1}(\mathbf{x}_i - \bar{\mathbf{x}})$$

$\bar{\mathbf{x}}$ es el vector de promedios de los \mathbf{x}_i y \mathbf{X}^* es la matriz de dimensión $n \times (p-1)$ cuya i -ésima fila es el vector $(\mathbf{x}_i - \bar{\mathbf{x}})'$.

El **leverage** mide la distancia entre la i -ésima observación y el vector de promedios.



Valores atípicos





¿Por qué puede influir tanto una observación?

$$\begin{aligned} E(r_i) &= 0 \\ \text{Var}(r_i) &= \sigma^2(1 - h_{ii}) \end{aligned}$$

Cuanto mayor sea h_{ii} menor es la varianza de r_i

Definición (**Distancia de Cook**)

Llamemos $\hat{\beta}$ y $\hat{\beta}_{(i)}$ a los estimadores OLS usando los datos completos y los datos sin la i -ésima observación. Sean

$$\begin{aligned}\hat{\mathbf{y}} &= \mathbf{X}\hat{\beta} \\ \hat{\mathbf{y}}_{(i)} &= \mathbf{X}\hat{\beta}_{(i)}\end{aligned}$$

Definimos la distancia de Cook de la i -ésima observación por

$$D_i = \frac{1}{pS^2} \|\hat{\mathbf{y}}_{(i)} - \hat{\mathbf{y}}\|^2 = \frac{r_i^2}{S^2 p} \frac{h_{ii}}{(1 - h_{ii})^2}$$



Criterios clásicos para la distancia de Cook

Observación influyente

- $D_i \geq F(p, n - p, 0,50)$
- $D_i > 1$

Observación con alto leverage


- $h_{ii} > 2\bar{h} = \frac{2}{n} \sum h_{jj} = \frac{2p}{n}$ (ajustado por la cantidad de covariables)
- $h_{ii} > 0,5$ (sin ajustar por la cantidad de covariables)



Problema: El leverage está basado en promedios, que es una medida poco robusta.

Ejemplo (**Ejemplo 5.2 de [Maronna et al., 2019]**)

Este ejemplo se basa en datos modificados de peso específico de madera, los datos cuentan con 20 casos con 5 variables explicativas donde las observaciones 4, 6, 8 y 19 fueron reemplazadas por valores atípicos (dataset wood).





M estimador de regresión

Definimos el M estimador de regresión como:

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n \rho \left(\frac{r_i(\beta)}{\hat{\sigma}} \right)$$

diferenciando la ecuación anterior tenemos

$$\sum_{i=1}^n \psi \left(\frac{r_i(\hat{\beta})}{\hat{\sigma}} \right) \mathbf{x}_i = \mathbf{0}$$

Definición (función ρ)

- Si $0 \leq u \leq v \Rightarrow \rho(u) \leq \rho(v)$.
- $\rho(u) = \rho(-u)$.
- ρ es derivable.
- ρ debe ser acotada.

Definición (función ψ)

Es una función que es derivada de una función ρ .

- ψ es impar y $\psi(x) \geq 0 \forall x \geq 0$.





■ ρ de Huber

$$\rho_k(x) = \begin{cases} x^2 & \text{si } |x| \leq k \\ 2k|x| - k^2 & \text{si } |x| > k \end{cases}$$

■ ρ bicuadrada

$$\rho_k(x) = \begin{cases} 1 - \left[1 - \left(\frac{x}{k}\right)^2\right]^3 & \text{si } |x| \leq k \\ 1 & \text{si } |x| > k \end{cases}$$



Funciones ψ 

- Los M- estimadores correspondientes a funciones ψ monótonas se llaman M-estimadores monótonos.
- Los M- estimadores correspondientes a funciones ψ que tienden a cero en $\pm\infty$ se llaman **M-estimadores redescendientes**.

Para protegerse de los outliers de alto leverage y del efecto de enmascaramiento resulta imprescindible usar M - estimadores redescendientes.



¿ Cómo calcular los M-estimadores ?

- 1 Calcular un estimador inicial $\hat{\beta}_0$ robusto que no necesite un estimador de escala previo.
- 2 Calcular los residuos $r_i(\hat{\beta}_0)$ correspondientes al ajuste anterior y estimar $\hat{\sigma}$ con un estimador robusto.
- 3 Encontrar la solución $\hat{\beta}$ de

$$\sum_{i=1}^n \psi \left(\frac{r_i}{\hat{\sigma}} \right) \mathbf{x}_i = \mathbf{0}$$

usando un método iterativo con $\hat{\beta}_0$ como estimador inicial.



Consideremos las ecuaciones de estimación:

$$\sum_{i=1}^n \psi \left(\frac{y_i - \mathbf{x}_i' \boldsymbol{\beta}}{\hat{\sigma}} \right) \mathbf{x}_i = \mathbf{0}$$



Consideremos las ecuaciones de estimación:

$$\sum_{i=1}^n \psi \left(\frac{y_i - \mathbf{x}'_i \beta}{\hat{\sigma}} \right) \mathbf{x}_i = 0$$

$$\sum_{i=1}^n \underbrace{\frac{\psi \left(\frac{y_i - \mathbf{x}'_i \beta}{\hat{\sigma}} \right)}{\frac{y_i - \mathbf{x}'_i \beta}{\hat{\sigma}}}}_{W_i} \left(\frac{y_i - \mathbf{x}'_i \beta}{\hat{\sigma}} \right) \mathbf{x}_i = 0$$

Consideremos las ecuaciones de estimación:

$$\sum_{i=1}^n \psi \left(\frac{y_i - \mathbf{x}_i' \beta}{\hat{\sigma}} \right) \mathbf{x}_i = 0$$

$$\sum_{i=1}^n \underbrace{\frac{\psi \left(\frac{y_i - \mathbf{x}_i' \beta}{\hat{\sigma}} \right)}{\frac{y_i - \mathbf{x}_i' \beta}{\hat{\sigma}}}}_{W_i} \left(\frac{y_i - \mathbf{x}_i' \beta}{\hat{\sigma}} \right) \mathbf{x}_i = 0$$

$$\sum_{i=1}^n W_i \left(\frac{y_i - \mathbf{x}_i' \beta}{\hat{\sigma}} \right) \mathbf{x}_i = 0$$



MM - estimador

Yohai (1987) propone un método de estimación para obtener una robustez y eficiencia óptimas. Usar un S estimador para la estimación inicial $\hat{\beta}_0$ y usar un M- estimador de escala para la estimación de $\hat{\sigma}$, los estimadores resultantes con este proceso se conocen como MM - estimadores.

Definición (**S-estimador**)

$$\frac{1}{n} \sum_{i=1}^n \rho \left(\frac{r_i}{\widehat{\sigma}} \right) = \delta$$

$\delta \in (0,1)$, *usualmente usamos* $\delta = 0,5$



Modelo de regresión logística

$$y_i \sim B(1, p_i)$$

$$p_i = F(\boldsymbol{\beta}' \mathbf{x})$$

dónde

$$F(y) = \begin{cases} \frac{e^y}{1+e^y} & \text{Modelo logístico} \\ \Phi(y) & \text{Modelo probit} \end{cases}$$

F^{-1} : Función de enlace



Estimador de máxima verosimilitud

$$\begin{aligned}
 \hat{\beta} &= \arg \max \sum_{i=1}^n \log(p_i^{y_i} (1 - p_i)^{1-y_i}) \\
 &= \arg \max \sum_{i=1}^n y_i \log(p_i) + (1 - y_i) \log(1 - p_i) \\
 &= \arg \min \sum_{i=1}^n -y_i \log(p_i) - (1 - y_i) \log(1 - p_i) \\
 &= \arg \min \sum d(y_i, p_i)
 \end{aligned}$$


Valores atípicos e influyentes



M Estimadores de regresión



Regresión Logística




Valores atípicos e influyentes






M Estimadores de regresión



Regresión Logística









Mínimos cuadrados pesados

Carroll and Pederson (1993) proponen el estimador

$$\hat{\beta} = \arg \min \sum_{i=1}^n w_i [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

con $w_i = W(h_n(\mathbf{x}_i))$ donde W es una función no decreciente tal que $W(u)u$ es acotada.



Pregibon (1981) propone el estimador

$$\hat{\beta} = \arg \min \sum_{i=1}^n \rho(d(y_i, p_i))$$

Bianco and Yohai (1996) observaron que en algunos casos este estimador no cumple la condición de consistencia de Fisher y proponen el siguiente estimador



Estimador Bianco-Yohai

$$\hat{\beta} = \arg \min \sum_{i=1}^n [\rho(d(p_i, y_i)) + q(p_i)]$$

$$q(u) = \nu(u) + \nu(1 - u)$$

$$\nu(u) = 2 \int_0^u \psi(-2 \log t) dt$$

$q(p_i)$ es una corrección para garantizar la consistencia de Fisher.



Croux and Haesbroeck (2003) describen condiciones suficientes para en la función ρ para garantizar el mínimo

$$\psi_c^{CH} = \exp\left(-\sqrt{\max(u, c)}\right)$$

Luego la ecuación de estimación resultante es



$$\sum_{i=1}^n p_i(\beta)(1-p_i(\beta)) [\psi(-2\log p_i(\beta)) - \psi(-2\log(1-p_i(\beta)))] \mathbf{x}_i = \mathbf{0}$$

- El resultado anterior garantiza que el estimador cumpla la condición de consistencia de Fisher.
- Bianco and Yohai (1996) probaron que el estimador es asintoticamente normal.
- La función Ψ resulta no ser acotada, **Croux and Haesbroeck (2003)** propone reducir la ponderación de las observaciones con alto leverage.



M estimador redescendiente ponderado

$$\beta = \arg \min \sum_{i=1}^n w_i [\rho(d(p_i(\beta), y_i)) + q(p_i(\beta))]$$





Ejemplos

Ejemplo

Datos correspondientes a 33 pacientes que padecen leucemia, la variable respuesta vale 1 cuando el paciente sobrevive más de 52 semanas y las dos covariables observadas son:

WBC: Número de glóbulos blancos.

AG: Presencia o ausencia de cierta característica morfológica en los glóbulos.



Bibliografía



Bianco, A. M. (1990).

M-estimadores robustos para regresión binominal y multinominal.

PhD thesis, Universidad de Buenos Aires.

Facultad de Ciencias Exactas y Naturales.



Maronna, R. A., Martin, R. D., Yohai,
V. J., and Salibián-Barrera, M. (2019).

Robust statistics: theory and methods (with R).

John Wiley & Sons.